



LSTM+EWC 기반의 지속 학습 접근법

스마트 농산물 가격 예측 서비스 - 딱대

중앙대학교 소프트웨어학부
배성빈, 이우중, 이찬우

목차

1. 개요 및 배경

1.1 서비스적 측면

1.2

2. 모델링, 배치학습 위주로

2.1 모델링 - 작물별 EDA

2.2 모델링 - 배치 학습 과정

2.3 지속 학습 도입

3. 지속학습 도입 배경

3.1 지속학습 도입 배경

3.2 규제기반 EWC 지속학습 모델

3.3 2025-06-13(금) 현재

4. 시스템 아키텍처 및 구현


4.1 시스템 아키텍처,


4.2 아키텍처 다이어그램

4.3 시퀀스 다이어그램

4.4 서비스 시연

5. 결론





1. 배경, 우리서비스의 필요성

1.1 이해관계자들

농민, 유통업자들, 정부관계자들

1.2 기능적 측면


Continual learning, LSTM+EWC의 확장성



1. 배경, 우리서비스의 필요성

[경제산책] 농산물 파동 반복과 스마트팜 활성화

입력 : 2021-07-12 00:00 | 수정 : 2021-07-09 22:42



<https://www.nongmin.com/article/20210709341339#:~:>

마스크 같은 공산품은 가격 변동에 따라 공급량이 조절돼 얼마 지나지 않아 시장가격은 안정된다. 하지만 공산품과 달리 농산물은 가격이 오르거나 내리더라도 수요량이나 공급량을 신속하게 조절하기 어렵다. 양파·마늘·배추 등의 농산물 파동 원인이 여기에 있다. 수요량과 시장가격의 조정 속도에 비해 공급의 조정 속도가 매우 느리기 때문이다.

1.1 서비스적 필요성 (농민)

경향신문

오피니언 정치 경제 사회 국제 문화 매거진L

경제


2~3년마다 폭등·폭락하는 양파값, 방법은 없나?

수정 2019.07.05 22:13

박은하 기자

도매가격 5320원...평년의 36%
작년 시세 좋은 작물 올해 재배
2년 주기 폭락·폭등 '널뛰기'
전국·전문적인 농업 통계 필요

최근 10년간 양파 소비자가격과 재배면적 자료: 농수산물유통정보센터·동계청



최병욱 농촌경제연구원 연구위원은 "농민들은 당해 시세(가격)를 보고 이듬해 심을 작물을 결정한다. 통계와 과세자료가 부실해 농산물이 어디서 얼마나 생산이 되고 소비되는지 제대로 파악이 되지 않는다"고 말했다. 가격 외 수급을 예측할 만한 별다른 정보가 제공되지 않다보니 농민들은 익숙한 '5대 작물' 가운데 당해 가격이 높았던 작물로 재배가 몰리면서 2년 주기로 폭락과 폭등이 반복한다는 것이다.

https://www.khan.co.kr/article/201907052051005?utm_source

농민신문 지역&현장

구독신청

농촌사회 지역소식 객원기자뉴스

f x N y i

수입확대·생산과잉·소비부진... '삼중고' 양파농가 "수급안정 대책 마련을"

입력: 2025-05-22 15:21 | 수정: 2025-05-23 05:00

🔊 📖 🗨️

성급했던 TRQ 양파 도입 등
시장 과잉물량 10만t 이를 뜻
채소가격안정 수급관리 '심각'
향후 시세급락 우려 산지 긴장감

"수매·비축 물량 발표 서두르고
수출 모색·소비 촉진 나서야"



기획·연재



[세 정부에 바란다] 농사로 버는 돈 적고 불안정...안전망 넓히고...



세 정부 이행 '이



[세 정부에 바란다] "농업예산 최소 5%까지 회복을...농정...



[맛있는 가지각?

올해 2월까지만 해도 추위 때문에 생육이 더뎠지만 3~4월 들어 풍부한 일조량 등 기상 여건이 좋아 양파 수량이 늘고 구가 비대해졌다"고 말했다.

◆ '삼중고'에 불안감 상승=작황 호조는 농가의 불안감을 증폭시키고 있다. 양파 수입 확대와 소비부진으로 양파값이 약세인데 생산량까지 증가하면 가격이 더 떨어질 수 밖에 없기 때문이다.

가격 하락은 이미 심각한 수준이다. 21일 기준 서울 가락시장의 상품 1kg 평균가격은 642원인데, 이는 채소가격안정사업 수급관리 가이드라인상 수확기(4~7월) 기준가격 651원 이하라서 '하락 심각' 단계에 해당한다.

https://www.nongmin.com/article/20250521500697?utm_source

농민의 입장에서

출하 시점과 작물 선택 결정에 도움을 줍니다

농민은 도매가 예측을 통해 출하 시점을 조절할 수 있습니다.

예: "다음 주에 가격이 떨어질 전망이면 출하를 미루자"

또한 작기 전 작물 선택에도 영향을 줍니다.

예: "여름에 고구마는 가격이 내려가고, 감자는 상승할 조짐 → 감자 쪽 재배 확대"

이런 결정이 바로 소득 안정으로 이어집니다.

왜 도매가냐?

- 농산물 가격은 산지->도매시장 ->소매시장 ->소비자 순으로 흘러가는데, 도매가는 그 중간 허리이자 기준점 역할을 합니다.
- 도매가격이 올라가면 소매가도 오르고, 소비자가격이 불안정해지며, 시장 전체에 영향을 미칩니다.
- 따라서 도매가를 사전에 예측하면 유통인·소비자가격 결정에 이르기까지 모든 주체가 전략을 세울 수 있는 기준 정보를 가지게 됩니다.

유통과정의 첫 번째 기준점이 도매가격

한국농정

[2023 농업결산] 농산물 가격에 위기 더한 '정부 수입'과 유통 분야 새바람



지난 7월 1일 경남 창원군 대지면 창녕농협 농산물공판장에서 올해 햅미늘의 첫 경매를 알리는 초미식이 열린 가운데 미늘 농사를 짓는 박운환 (86)씨가 경매장 한편에 앉아 마늘 경락가가 나타나는 전광판을 응시하고 있다. 한승호 기자

매년 반복되는 양상이지만, 올해는 유독 농산물 가격폭락으로 인한 농민들의 원성이 거셌다. '소비자 물가 안정'이라는 그럴듯한 명분을 앞세운 채 강제·반복된 저율관세할당물량(TRQ)·무관세 농산물 수입 때문이다.

관계부처합동

보도자료

다시 대한민국!
새로운 국민의 나라

보도시점 2024. 5. 1.(수) 08:00 배포 2024. 4. 30.(화) 09:00

농수산물 유통경로 다양화와 경쟁 촉진을 통해 유통비용 10% 이상 절감

- 도매시장 경쟁 확대, 불공정 행위 엄단, 온라인도매시장 활성화('27년: 5조 원) -

유통인 입장: 재고 확보·물류비 절감

유통업자는 가격이 오를 것으로 예측되면 미리 확보, 떨어질 경우엔 재고 축소 등 전략적 결정을 내릴 수 있습니다.

이는 재고 손실을 줄이고, 물류비를 최적화할 수 있는 핵심 도구입니다.

특히, 배추·무처럼 가격이 며칠 사이에 폭등하거나 폭락하는 작물에서는 예측 정보가 큰 가치를 가집니다.

2025년 6월 12일(목)

뉴데일리경제

☰ 🔍 VOD뉴스 최신기사 정책 산업 부동산 IT·전자 금융 증권 유통 제약·의료 전국뉴스 ▾

농식품부, 제7기 농산물 수급조절위 개최 ... 채소 수급 '선제 대응' 돌입

최은서 기자
입력 2025-06-12 17:00 | 수정 2025-06-12 17:00

농산물 수급관리 지침 개정 사항 논의
김관수 서울대 교수, 민간위원장 재선출



https://biz.newdaily.co.kr/site/data/html/2025/06/12/2025061200323.html

동아일보

오피니언 정치 경제 국제 사회 문화 연예 스포츠 헬스동아 트렌드뉴스

경제

배추·무·양파 등 채소류 작황 양호·가격 안정적...수급 조절·할인지원 지속

뉴스(신문) | 업데이트 2025-05-28 11:11 ▾

0 0

여름배추·무 병해충 방제 지원...수매비축 확대
양파 자조금 활용 출하 억제 등 과잉물량 해소
비축물량 깎마늘 가공 후 도매시장 분산 공급



https://www.donga.com/news/Economy/article/all/20250528/131699400/

그래서!

도매가격 예측은 단순 정보 제공을 넘어서,

농가와 유통인은 출하량·작물선택 전략을 세우고,

정부는 비축·수매·수입 조정 같은 선제 대응을 할 수 있습니다.

1.2 기능적 측면

LSTM (Long Short-Term Memory)

- 시계열 데이터의 **장기 의존성(long-term dependency)**을 효과적으로 학습
- 계절성, 주기성, 갑작스러운 수급 변동이 반복되는 농산물 가격 예측에 최적화된 구조

EWC (Elastic Weight Consolidation)

- 지속학습(Continual Learning) 기반 정규화 기법
- 이전 시점의 학습 정보를 보존하면서 새로운 데이터에 적응 가능
- 농산물처럼 연도별 패턴은 유지되면서도, 새로운 기후·유통 요인이 생기는 상황에 매우 적합함


단순 LSTM보다 시계열 추세의 안정적 유지와 개별 연도 예외 상황 반영을 동시에 실현

매년 학습을 리셋하지 않고 데이터를 누적하면서도 이전 학습이 무너지지 않음
(catastrophic forgetting 방지)

사회적 확장 가능성: 농산물 → 에너지 도메인 등

적용 분야	예시	사회적 가치
전력	전력 사용량, 수요예측, ESS 제어	에너지 효율화, 전력 피크 감축, 탄소 배출 저감
수자원	하천 수위, 댐 유입량, 수도 사용량	기후위기대응, 물 공급 계획 최적화
교통	교통량·혼잡도, 대중교통 수요	도시 혼잡 완화, 대중교통 운용 최적화
보건	병상 수요, 질병 발생 추이	공공 의료자원 분배, 예방 정책 강화

농산물 가격 예측은 시계열 예측 기술의 사회적 적용성을 보여주는 대표적 사례이며,
우리 모델은 다양한 공공영역에도 확장 가능하다는 점에서 기술의 공공성·지속 가능성을 동시에 확보합니다.



2. 모델링 과정

2.1 모델링 - 작물별 EDA




2.2 모델링 - 배치 학습 과정

2.3 지속 학습 도입






2.1 모델링 - 작물별 EDA

배추 (상)
2016 ~ 2025 6월






2.1 모델링 - 작물별 EDA




양파 (상)
2016 ~ 2025 6월






2.1 모델링 - 작물별 EDA 감자 (상) 2016 ~ 2025 6월






2.1 모델링 - 작물별 EDA 무 (상) 2018~ 2025 6월



2.1 모델링 - 작물별 EDA 고구마 (상) 2018~ 2025 6월




2.1 모델링 - 작물별 EDA 토마토 (상) 2018~ 2025 6월



2.1 모델링 작물별 EDA

DBSCAN으로
비슷한 동향의 가격 clustering

2025	5	30	113	6380	594
2025	5	30	16	7510	779
2025	5	31	107	6262	-118
2025	5	31	15	8069	559
2025	6	2	133	7400	1138
2025	6	2	19	9471	1402
2025	6	3	141	6409	-991
2025	6	3	20	9305	-166
2025	6	4	110	7646	1237
2025	6	4	16	11282	1977
2025	6	5	142	6829	-817
2025	6	5	20	10054	-1228
2025	6	6	134	6647	-182
2025	6	6	19	9029	-1025
2025	6	7	116	7175	528
2025	6	7	17	9297	268
2025	6	9	124	7035	-140
2025	6	9	18	8539	-758
2025	6	10	135	6093	-942
2025	6	10	19	7737	-802



공휴일, 휴일관계없이
데이터가 안들어오는 날이
안정해져있음

2.2 데이터 전처리



이상치

log, lag, 푸리에변환시도



주말, 공휴일처리

결측치 처리
보간시도



날씨 데이터 제외

생산지 공공데이터 부족
우리의 상황적한계
기존엔 서울 날씨 활용했지만
영향 미비

전처리 로직, 모듈화

```
# 파일 경로
onion_path = 'data/PotatoPrice.xlsx'
intake_path = 'data/PotatoIntake.xlsx'

# 시트 불러오기
onion_df = pd.read_excel(onion_path, sheet_name=0)
intake_df = pd.read_excel(intake_path, sheet_name=0)

# 0원인 데이터 제거
filtered = filtered[filtered['avg_price'] != 0]

# 레이블, 비율 컬럼 추가
filtered['rate'] = filtered['등급명'].map(lambda x: grade_ratio[x][0])
filtered['비율'] = filtered['등급명'].map(lambda x: grade_ratio[x][1])

# 반입량 합치기
intake_df = intake_df[['DATE', '총반입량']].copy()
intake_df.rename(columns={'총반입량': 'total_intake'}, inplace=True)

merged = pd.merge(filtered, intake_df, on='DATE', how='inner')

# 날짜 분해
merged[['year', 'month', 'day']] = merged['DATE'].astype(str).str.split('-', expand=True).astype(int)

# gap 계산 (같은 등급 기준 전날과의 가격 차이)
merged.sort_values(['rate', 'DATE'], inplace=True)
merged['gap'] = merged.groupby('rate')['avg_price'].diff().fillna(0).astype(int)
```


2.3 중간과정, 배치학습

초기 모델링에서는 XGBoost와 DLinear 기반의 배치 학습(Batch Training) 방식으로 진행했습니다. 중간발표 시점까지는 과거 데이터를 기반으로 한 번 학습하고, 이후 예측에 사용하는 방식이었습니다.

XGBoost: 비선형적 특성을 잘 학습하지만, 시계열 추세(trend) 반영에는 한계가 존재

DLinear: 시계열 데이터의 추세(trend)와 계절성(seasonality)을 간결하게 분해하여 예측하는 특성을 가짐




Figure 2: Illustration of the Decomposition Linear Model.



그런데 여기서 고민점..

아니 배치학습을 매일 해야함?
매일 데이터 들어올때마다 학습을 매번 새롭게?
그리고 뚜렷한 계절성을 가진 데이터를 활용할 수 있을까?





3.1 지속학습 도입 배경



계절성이 뚜렷함

농산물 가격은 계절 변화에 따라 반복적인 패턴을 보입니다.
그러나 연도별로 계절성이 완전히 동일하지 않기 때문에, 단순 반복 학습이 아니라 점진적 적응(지속학습)이 효과적입니다.

반복 리소스 활용

작물 수가 늘어나면, 모든 데이터를 매번 전체 학습하는 배치 학습 방식은 비용과 시간이 많이 듭니다.
지속학습은 변동된 일부 데이터만 반영해 모델을 업데이트하므로,
전체 연산량과 학습 시간을 줄일 수 있습니다.

온라인학습에 적합

하루에 한번씩 데이터가 들어오는 온라인 학습인데
전체 데이터를 다시 불러와서 학습하는 것보다 지속학습하는 것이 보다 더 효율적이다.



다른 방법론에 대한 고민 by 리플레이기반



리플레이 기반 학습이란?

과거 특정 데이터를 저장해두었다가, 새로운 데이터를 학습할 때 함께 다시 학습에 사용하는 방식입니다.

하지만

리플레이는 과거 샘플을 무작위로 섞어 사용해야 하므로 시계열 순서 특성(time dependency)이 깨질 수 있습니다
시계열 예측에서는 과거 흐름이 중요하기 때문에, 리플레이로 과거를 "조각"내면 추세 예측력 저하됩니다

그래서 선택한 규제기반 EWC 지속학습 모델

1. 중요한 지식 유지:

과거에 학습한 계절성, 주기성, 추세성 등 중요한 패턴 파라미터를 고정시킴

예: "추석에는 배추 가격이 오름" 같은 규칙을 망각하지 않도록 보호

2. 데이터 저장 없이도 성능 유지:

EWC는 데이터가 아니라 파라미터 중요도만 보존하므로, 온라인 학습과 잘 맞음

하루 단위로 업데이트되는 가격예측에 적합

3. 계산이 비교적 효율적:

리플레이처럼 GAN이나 메모리 관리 없이, 비교적 단순한 추가 loss term만으로 학습 가능

4. 과거 잊지 않음:

새로운 정책, 기후 등으로 변화가 있을 때도, 기존의 중요한 정보만 유지하고 나머지는 유연하게 바뀔 수 있음

규제 방식: EWC의 수식과 역할

기본 loss function(예: CrossEntropy, MSE 등)은 모델의 예측값과 실제값 사이의 오차를 최소화합니다.

EWC는 기존 task에서 학습한 가중치가 새 task에서 크게 변하지 않도록, loss에 규제 항을 추가해서 기존 지식이 사라지는(망각되는, catastrophic forgetting) 현상을 방지합니다.

$$\text{Total Loss} = \text{Task Loss} + \lambda \cdot \text{EWC Penalty}$$

Task Loss: 새로 학습하는 task에 대한 일반적인 loss (CrossEntropy 등)

EWC Penalty: 이전 task의 가중치(w^*)에서 현재 가중치(w)가 멀어지지 않도록 하는 항

$$\text{EWC Penalty} = \sum_i \frac{1}{2} F_i (w_i - w_i^*)^2$$

w_i^* : 이전 task에서의 i 번째 파라미터

w_i : 현재 파라미터

F_i : 피셔 정보 행렬(Fisher information matrix)에서 얻은 중요도(파라미터별로 얼마나 중요한지)

규제기반 지속학습의 문제점

Predictor.py, Predictor7.py, Predictor28.py

```
def fit(self, df_raw, cutoff_date="2025-05-20", months=[4, 5, 6], rate="SPECIAL"):
    self.rate = rate
    df = df_raw[df_raw['rate'] == rate].copy()
    df['date'] = pd.to_datetime(df[['year', 'month', 'day']])
    df = df[df['month'].isin(months)].sort_values('date').reset_index(drop=True)
    df['prev_price'] = df['avg_price'].shift(1)
    df['price_diff'] = df['avg_price'] - df['prev_price']
    df['rolling_mean'] = df['avg_price'].rolling(window=3).mean()
    df['rolling_std'] = df['avg_price'].rolling(window=3).std()
    df = df.dropna()
    df['log_price'] = np.log1p(df['avg_price'])

    self.scaler_x = MinMaxScaler()
    self.scaler_y = MinMaxScaler()
    df[self.feature_cols] = self.scaler_x.fit_transform(df[self.feature_cols])
    df[[self.target_col]] = self.scaler_y.fit_transform(df[[self.target_col]])

def update_one_day(self, df_raw, months=[4, 5, 6], rate="SPECIAL"):
    self.rate = rate
    df = df_raw[df_raw['rate'] == rate].copy()
    df['date'] = pd.to_datetime(df[['year', 'month', 'day']])
    df = df[df['month'].isin(months)].sort_values('date').reset_index(drop=True)
    df['prev_price'] = df['avg_price'].shift(1)
    df['price_diff'] = df['avg_price'] - df['prev_price']
    df['rolling_mean'] = df['avg_price'].rolling(window=3).mean()
    df['rolling_std'] = df['avg_price'].rolling(window=3).std()
    df = df.dropna()
    df['log_price'] = np.log1p(df['avg_price'])

    df[self.feature_cols] = self.scaler_x.transform(df[self.feature_cols])
    df[[self.target_col]] = self.scaler_y.transform(df[[self.target_col]])

    last_seq = torch.tensor(df.iloc[-self.WINDOW:][self.feature_cols].values, dtype=torch.float32).unsqueeze(0)
    last_target = torch.tensor(df.iloc[-1][self.target_col], dtype=torch.float32).unsqueeze(0)
```



이전 Task에서 중요한 파라미터의 변화를 억제하는 특성 때문에, 새로운 트렌드에 대한 빠른 파라미터 업데이트가 제한된다.

따라서 규제기반 지속학습 방식은 갑작스러운 데이터 분포의 변화(급등, 급락)에 적용하는 데 한계가 있다.

계절성이 뚜렷할때와 계절성이 없거나 벗어날때


감자(상)는
LSTM+EWC

무(상)는
Dlinear로 Batch




2025-06-13(금) 현재

작물	등급	학습 방식	분기
배추	HIGH	LSTM + EWC	6~7
배추	Special	LSTM + EWC	6~7
양파	HIGH	LSTM + EWC	6~11
양파	Special	LSTM + EWC	6~11
감자	HIGH	LSTM + EWC	6~8
감자	Special	LSTM + EWC	6~8
고구마	HIGH	DLinear (Batch)	x
고구마	Special	DLinear (Batch)	x
무	HIGH	DLinear (Batch)	x
무	Special	DLinear (Batch)	x
토마토	HIGH	LSTM + EWC	6~7
토마토	Special	LSTM + EWC	6~7




내일 가격: 20934.27
최신 예측 정보: {'year': 2025, 'month': 6, 'day': 11, 'price': 20934.27, 'rate': 'HIGH'}



내일 가격: 13350.16
최신 예측 정보: {'year': 2025, 'month': 6, 'day': 11, 'price': 13350.16, 'rate': 'HIGH'}

추세가 맞을때
LSTM+EWC

추세가 잘 맞지 않을때
DLinear(batch)



3.2 우리 방법론 (LSTM+EWC 방법론)의 강점

1. Explainability
(설명 가능성)

2. Sustainability
(지속 가능성)

3. Incremental
Learning
(지속 학습 능력)



우리 방법론 (LSTM+EWC 방법론)의 강점

Explainability (설명 가능성)

LSTM은 시간의 흐름을 따라 중요한 가격 패턴의 영향력을 명확히 시각화할 수 있고, EWC는 어떤 파라미터가 과거 학습에 중요했는지를 수치화(Fisher 정보량 기반)하여 모델이 무엇을 기억하고 무엇을 바꿨는지 설명할 수 있습니다.

Sustainability (지속 가능성)

한 번 학습된 모델을 계속 재사용하며 추가 학습할 수 있기 때문에 모델을 처음부터 다시 학습할 필요 없이 운영 효율성과 에너지 절감이 뛰어납니다.

Incremental Learning (지속 학습 능력)


새로운 데이터가 유입되어도 과거 지식을 유지하면서 예측 정확도를 장기적으로 안정적으로 유지할 수 있습니다.




4. 시스템 아키텍처 및 구현

- 4.1 시스템 아키텍처,
- 4.2 아키텍처 다이어그램
- 4.3 시퀀스 다이어그램
- 4.4 서비스 시연





4.1 시스템 아키텍처




4.2 아키텍처 다이어그램

4.3 지속 학습 및 배포 프로세스

- 1 매일 오전 8시가 되면 system은 설정된 Justick.service 파일을 실행합니다. Justick.service는 Justick_System의 실행 파일인 main.py를 실행합니다.
- 2 main.py에서는 데이터 수집, 데이터 전처리, 데이터 전송, 지속 학습, 가격 예측, 예측 데이터 전송을 한단계씩 수행합니다.
- 3 처음 크롤러가 실행되면 Firefox Driver를 이용하여 selenium 라이브러리를 통해 농넷에서 소매가격, 가락시작 가격과 반입량 데이터를 배추, 양파, 감자, 무, 고구마 토마토를 반복하며 크롤링 해옵니다
- 4 Preproccsor는 농넷에서 받아온 자료를 AI에서 활용하고 DB에 저장할 수 있도록 지정된 피쳐에 맞춰 전처리해줍니다.
- 5 DBwriter는 전처리된 실제 값을 Justick Spring에 Post 요청합니다.
- 6 Justick_Spring에서는 docker에서 백그라운드로 실행중인 Mysql에 데이터를 저장합니다.
- 7 다음으로 예측 모델을 실행시킵니다. 예측 모델은 사전 학습 모델이 저장되어 있고 날짜 하루가 들어오면 작물별, 등급별 지속학습을 진행한 뒤 28일치의 예측 값을 생성합니다.
- 8 예측한 값을 Spring에 post 요청합니다.
- 9 Main.py 단계가 끝나면 automation.sh를 실행시킵니다. automation은 root 권한을 통해 git에 접속해 Justick 파일들이 변경되었는지 감시합니다.
- 10 파일이 변경되었으면 git pull 명령어를 통해 받아옵니다.
- 11 Justick_React를 받아오면 npm run build를 통해 파일을 빌드 한 후 NGINX에 알려 NGINX가 빌드된 파일을 재반영합니다. NGINX를 통해 ddns에 외부 사용자가 접속할 수 있도록 설정합니다.
- 12 Justick_Spring을 받아오면 ./gradlew build 명령어로 파일을 빌드한 후 docker를 잠시 종료해 빌드된 파일을 반영하고 재시작합니다. 또한 NGINX에 알려 빌드된 파일을 재반영합니다.

4.3 시퀀스 다이어그램



4.3 시퀀스 다이어그램



크롤링 서버와 DB 서버 연동

- 크롤링 서버: 농산물 가격 데이터 수집
- 실시간 데이터 검증 및 전처리 수행
- DB 서버로 정제된 데이터 전송
- 데이터 무결성 검사 및 백업 프로세스
- 오류 발생 시 자동 알림 시스템 작동
- 보안 프로토콜을 통한 안전한 데이터 전송
- 서버 간 동기화로 데이터 일관성 유지



데이터 자동화 및 업데이트 프로세스

- 일일 데이터 업데이트 자동화 스케줄링
- 새로운 데이터 유입 시 증분 업데이트 수행
- 히스토리 데이터 관리 및 아카이빙
- 데이터 품질 모니터링 시스템 운영
- API를 통한 외부 시스템과의 연동
- 데이터 버전 관리 및 롤백 기능 구현
- 실시간 대시보드로 프로세스 모니터링

4.4 서비스 시연

<http://justick.myvnc.com:2025/>



5. 사회적 확장 가능성: 농산물 → 에너지 도메인 등

적용 분야	예시	사회적 가치
전력	전력 사용량, 수요예측, ESS 제어	에너지 효율화, 전력 피크 감축, 탄소 배출 저감
수자원	하천 수위, 댐 유입량, 수도 사용량	기후위기대응, 물 공급 계획 최적화
교통	교통량·혼잡도, 대중교통 수요	도시 혼잡 완화, 대중교통 운용 최적화
보건	병상 수요, 질병 발생 추이	공공 의료자원 분배, 예방 정책 강화

농산물 가격 예측은 시계열 예측 기술의 사회적 적용성을 보여주는 대표적 사례이며,
우리 모델은 다양한 공공영역에도 확장 가능하다는 점에서 기술의 공공성·지속 가능성을 동시에 확보합니다.



5.결론!

“우리는 다양한 작물의 시계열 특성에 맞춰

1. LSTM + EWC 모델을 설계하고

2. 크롤링 → 전처리 → 학습 → 예측 → 배포까지 전 과정
자동화파이프 라인(CI/CD)을 운영하고

3. 지속적으로 학습하고 적응하는 스마트 농산물 예측 시스템을 구축했습니다.”



들어주셔서 감사합니다! 한학기동안 모두 고생 많으셨어요!

Q&A 세션

2025. 06. 13 캡스톤 디자인(2)
배성빈, 이우중, 이찬우

